

Conformal Prediction by Examples

3. MEPS + CQR: The regression case

Byol Kim

August 19, 2025

지난 시간에는

분할 컨포멀 예측 워크플로


1. Score
2. Calibrate
3. Construct

바람직한 성질들

1. Validity ✓
2. Efficiency
3. Adaptivity


지난 시간에는

ImageNet 에 APS vs. LABEL 적용한 결과



지난 시간에는

ImageNet 에 APS 적용한 결과



이번 시간에는

회귀문제의 경우

1. 회귀문제

2. 회귀문제에 사용되는 논컨포미티 점수들

컨포멀화된 분위수 회귀 (conformalized quantile regression, CQR)

분위수 회귀

3. 주변 커버리지 보장

4. 다음 실습: MEPS 를 사용한 간단한 회귀 예제

예제 설명

회귀문제

$$(X, Y) \sim P, \quad X \in \mathcal{X}, \quad Y \in \mathcal{Y}$$

목표 X 에 상응하는 Y 를 예측

회귀 (regression)

- $|\mathcal{Y}| = \infty$ (비가산, uncountable)
- 예측오차: $|Y - \hat{f}(X)|$

분류 (classification)

- $|\mathcal{Y}| < \infty$
- 예측오류: $\mathbb{1}\{Y \neq \hat{f}(X)\}$

일반적인 분할 컨포멀 예측 워크플로

주어진 것 사전 훈련된 예측 모델 $\hat{f}$

1. Score

$$s(x, y) = s(x, y; \hat{f})$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\}$$

회귀문제든 분류문제든, 분할 컨포멀 예측집합은

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\}$$

회귀 (regression)

- $|\mathcal{Y}| = \infty$ (비가산)
- $|\hat{C}(x)| = \infty$ (비가산)
- $\hat{C}(x)$ 가 구간이라는 보장 $\times$

분류 (classification)

- $|\mathcal{Y}| < \infty$
- $|\hat{C}(x)| < \infty$

보통 각 논컨포미티 점수의 정의를 이용하여 계산에 용이한 형태를 유도해서 구현

회귀문제에 사용되는 논컨포미티 점수들

논컨포미티 점수 #1: 잔차 (residual)

$$s(x, y) = s(x, y; f) = |y - f(x)|$$

동기

$$Y = f^*(X) + \epsilon, \quad X \perp\!\!\!\perp \epsilon$$

Y 의 조건부분포가 $f^*(X)$ 를 중심으로

단봉 & 대칭, 그리고 등분산

일 때의 직관으로부터 온 형태

예측집합 형태

$$|y - f(x)| \leq \hat{q} \iff f(x) - \hat{q} \leq y \leq f(x) + \hat{q}$$

이므로

$$\hat{C}(x) = [f(x) - \hat{q}, f(x) + \hat{q}]$$

논컨포미티 점수 #2: 표준화 잔차 (scaled residual)

$$s(x, y) = s(x, y; f, \sigma) = |y - f(x)| / \sigma(x)$$

동기

$$Y = f^*(X) + \sigma^*(X)\epsilon, \quad X \perp\!\!\!\perp \epsilon$$

Y 의 조건부분포가 $f^*(X)$ 를 중심으로

단봉 & 대칭, 그러나 이분산

일 수도 있을 때의 직관으로부터 온 형태

예측집합 형태


$$|y - f(x)| / \sigma(x) \leq \hat{q} \iff f(x) - \hat{q}\sigma(x) \leq y \leq f(x) + \hat{q}\sigma(x)$$

이므로

$$\hat{C}(x) = [f(x) - \hat{q}\sigma(x), f(x) + \hat{q}\sigma(x)]$$

표면에 잡음을 더한 (surface-plus-noise) 모델

$Y = f^*(X) + \sigma^*(X)\epsilon$ 형태의 모델. 여기서, ϵ 은 백색잡음 (white noise)




Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression.

표면에 잡음을 더한 모델이 적합하지 않은 경우

조건부 α -분위수 $\tau_{\alpha}^*(X) = F^{-1}(\alpha; X) = \inf\{y : F(y | X) \geq \alpha\}$

$$\mathbb{P}\left\{\tau_{\alpha/2}^*(X) \leq Y \leq \tau_{1-\alpha/2}^*(X)\right\} = 1 - \alpha$$



Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression.


핀볼 손실 (pinball loss) 함수와 분위수 추정

평균 μ^* 의 경우

$$\mu^* = \arg \min_t \mathbb{E} [|Y - t|^2]$$

α -분위수 τ_α^* 의 경우

$$\tau_\alpha^* = \arg \min_t \mathbb{E} [\rho_\alpha(Y - t)]$$



$$\begin{aligned} \rho_\alpha(z) &= (\alpha - \mathbb{1}\{z < 0\})z \\ &= \begin{cases} (\alpha - 1)z & \text{for } z < 0 \\ \alpha z & \text{for } z \geq 0 \end{cases} \end{aligned}$$

핀볼 손실 (pinball loss) 함수와 분위수 추정

$$\begin{aligned}\mathbb{E}[\rho_\alpha(Y - t)] &= \int_{-\infty}^{\infty} \rho_\alpha(y - t) dF(y) \\ &= (\alpha - 1) \int_{-\infty}^t (y - t) dF(y) + \alpha \int_t^{\infty} (y - t) dF(y)\end{aligned}$$

라이프니츠 적분 법칙에 의해,

$$\begin{aligned}\frac{d}{dt} \int_{-\infty}^t (y - t) dF(y) &= - \int_{-\infty}^t dF(y) = -F(t) \\ \frac{d}{dt} \int_t^{\infty} (y - t) dF(y) &= - \int_t^{\infty} dF(y) = -(1 - F(t))\end{aligned}$$

이므로 $\frac{d}{dt} \mathbb{E}[\rho_\alpha(Y - t)] = 0$ 의 해는

$$-(\alpha - 1)F(t) - \alpha(1 - F(t)) = F(t) - \alpha = 0$$

을 만족. 즉,

$$t = F^{-1}(\alpha) = \tau_\alpha^*$$

분위수 회귀

분위수 회귀

목적 조건부 α -분위수 $\tau_{\alpha}^*(x)$ 추정

표본 절차 $\tau_{\alpha}^* \in \mathcal{F}$ 라 가정,

$$\min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \rho_{\alpha}(Y_i - f(X_i))$$

일반 회귀

목적 조건부 평균 $\mu^*(x)$ 추정

표본 절차 $\mu^* \in \mathcal{F}$ 라 가정,

$$\min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n |Y_i - f(X_i)|^2$$

딥 러닝을 활용한 많은 분위수 회귀 방법론들이 나와 있음

$$\mathbb{P} \left\{ \tau_{\alpha/2}^*(X) \leq Y \leq \tau_{1-\alpha/2}^*(X) \right\} = 1 - \alpha$$

문제?

- 진짜 분위수 함수 $\tau_{\alpha}^*(x)$ 를 모름

$$\mathbb{P} \left\{ \tau_{\alpha/2}^*(X) \leq Y \leq \tau_{1-\alpha/2}^*(X) \right\} = 1 - \alpha$$

문제?

- 진짜 분위수 함수 $\tau_{\alpha}^*(x)$ 를 모름
- $\tau_{\alpha}^*(x)$ 를 $\hat{\tau}_{\alpha}(x)$ 로 대체

$$\mathbb{P} \left\{ \tau_{\alpha/2}^*(X) \leq Y \leq \tau_{1-\alpha/2}^*(X) \right\} = 1 - \alpha$$

문제?

- 진짜 분위수 함수 $\tau_{\alpha}^*(x)$ 를 모름
- $\tau_{\alpha}^*(x)$ 를 $\hat{\tau}_{\alpha}(x)$ 로 대체
- 커버리지 보장 불가

$$\mathbb{P} \left\{ \tau_{\alpha/2}^*(X) \leq Y \leq \tau_{1-\alpha/2}^*(X) \right\} = 1 - \alpha$$

문제?

- 진짜 분위수 함수 $\tau_{\alpha}^*(x)$ 를 모름
- $\tau_{\alpha}^*(x)$ 를 $\hat{\tau}_{\alpha}(x)$ 로 대체
- 커버리지 보장 불가
- **컨포멀화 (conformalizing)** 문제의 구조에서 얻은 영감을 바탕으로 논컨포미티 점수를 설계, 분할 컨포멀 예측을 시행
 $\rightsquigarrow$ **CQR(conformalized quantile regression)** 논컨포미티 점수

$$s(x, y) = s(x, y; \tau) = \max\{\tau_{\alpha/2}(x) - y, y - \tau_{1-\alpha/2}(x)\}$$

- 커버리지 초과? $\tau_{\alpha/2}(x) \leq y \leq \tau_{1-\alpha/2}(x)$ $\rightsquigarrow s(x, y) \leq 0$
- 커버리지 미달? $y < \tau_{\alpha/2}(x)$ 또는 $y > \tau_{1-\alpha/2}(x)$ $\rightsquigarrow s(x, y) > 0$

예측집합 형태

$$\begin{aligned} s(x, y) = \max\{\tau_{\alpha/2}(x) - y, y - \tau_{1-\alpha/2}(x)\} &\leq \hat{q} \\ \iff \tau_{\alpha/2}(x) - y &\leq \hat{q} \text{ and } y - \tau_{1-\alpha/2}(x) \leq \hat{q} \\ \iff \tau_{\alpha/2}(x) - \hat{q} &\leq y \leq \tau_{1-\alpha/2}(x) + \hat{q} \end{aligned}$$

이므로

$$\hat{C}(x) = [\tau_{\alpha/2}(x) - \hat{q}, \tau_{1-\alpha/2}(x) + \hat{q}]$$

주변 커버리지 보장

주변 커버리지 보장

Q 회귀문제에서 각 논컨포미티 점수를 사용한 분할 컨포멀 예측은 주변 커버리지를 보장할까?

주변 커버리지 보장

Q 회귀문제에서 각 논컨포미티 점수를 사용한 분할 컨포멀 예측은 주변 커버리지를 보장할까?

핵심!!

$$\mathbb{P}\{S_{n+1} \leq S_{(k)}\} = \frac{k}{n+1}, \quad k = 1, \dots, n$$

- $S_1, \dots, S_n, S_{n+1}$ 모두 독립동일분포
- 모든 j 에 대해 S_{n+1} 가 $S_1, \dots, S_n, S_{n+1}$ 중 j 번째 작은 수일 확률 $= \frac{1}{n+1}$
- $S_{(0)} = -\infty, S_{(j)} = S_{(n;j)}$ 를 $S_1, \dots, S_n$ 중 j 번째 작은 수라 두면

$$\mathbb{P}\{S_{n+1} \leq S_{(k)}\} = \sum_{j=1}^k \mathbb{P}\{S_{(j-1)} \leq S_{n+1} \leq S_{(j)}\} = \sum_{j=1}^k \frac{1}{n+1} = \frac{k}{n+1}$$

이론적으로는 회귀 상황으로 인한 변화 없음!!

조건부 커버리지 보장

Q 회귀문제에서 각 논컨포미티 점수를 사용한 분할 컨포멀 예측은 조건부 커버리지를 보장할까?

조건부 커버리지 보장

Q 회귀문제에서 각 논컨포미티 점수를 사용한 분할 컨포멀 예측은 조건부 커버리지를 보장할까?

A 추가 가정 없이는 불가능. 이것은 CQR 논컨포미티 점수도 동일

**다음 실습: MEPS 를 사용한 간단한
회귀 예제**

MEPS(Medical Expenditure Panel Survey, 의료비 지출 패널 조사) 데이터

전처리된 2015 년과 2016 년 데이터

- X : 환자의 인구학적 특성 및 건강 상태
- Y : 로그 의료지출 (단위: 로그 \$)

튜토리얼 데이터셋에는 회귀 및 분위수 회귀 모델 학습 결과도 포함:

- `pred`: 사전 훈련된 모델의 Y 예측값
- `upper`: 사전 훈련된 분위수 모델의 0.95-분위수 추정값 $\hat{\tau}_{0.95}(X)$
- `lower`: 사전 훈련된 분위수 모델의 0.05-분위수 추정값 $\hat{\tau}_{0.05}(X)$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #1 의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$

1. Score

$$s(x, y) = |y - \hat{f}(x)|$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} =$$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #1 의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$

1. Score

$$s(x, y) = |y - \hat{f}(x)|$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} = [\hat{f}(x) - \hat{q}, \hat{f}(x) + \hat{q}]$$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #2 의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$ 과 잡음 예측 모델 $\hat{\sigma}$

1. Score

$$s(x, y) = |y - \hat{f}(x)| / \hat{\sigma}(x)$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{ 의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} =$$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #2 의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$ 과 잡음 예측 모델 $\hat{\sigma}$

1. Score

$$s(x, y) = |y - \hat{f}(x)| / \hat{\sigma}(x)$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{ 의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} = [\hat{f}(x) - \hat{q}\hat{\sigma}(x), \hat{f}(x) + \hat{q}\hat{\sigma}(x)]$$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #3 의 경우

주어진 것 사전 훈련된 분위수 회귀 모델 $\hat{\tau}$

1. Score

$$s(x, y) = \max\{\hat{\tau}_{\alpha/2}(x) - y, y - \hat{\tau}_{1-\alpha/2}(x)\}$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} =$$

분할 컨포멀 예측 워크플로: 논컨포미티 점수 #3 의 경우

주어진 것 사전 훈련된 분위수 회귀 모델 $\hat{\tau}$

1. Score

$$s(x, y) = \max\{\hat{\tau}_{\alpha/2}(x) - y, y - \hat{\tau}_{1-\alpha/2}(x)\}$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$

$\hat{q} = S_1, \dots, S_n$ 중 $\lceil (n+1)(1-\alpha) \rceil$ 번째 작은 수

$$= \frac{1}{n} \sum_{i=1}^n \delta_{S_i} \text{ 의 } \left(1 + \frac{1}{n}\right) (1-\alpha)\text{-분위수}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\} = [\hat{\tau}_{\alpha/2}(x) - \hat{q}, \hat{\tau}_{1-\alpha/2}(x) + \hat{q}]$$

요약

1. 회귀문제

2. 회귀문제에 사용되는 논컨포미티 점수들

컨포멀화된 분위수 회귀 (conformalized quantile regression, CQR)

분위수 회귀

3. 주변 커버리지 보장

4. 다음 실습: MEPS 를 사용한 간단한 회귀 예제

예제 설명

다음 실습 내용

코드를 완성하여 직접 회귀 상황에서의 분할 컨포멀 예측 구현

세 가지 논컨포미티 점수를 동시에 사용, 논컨포미티 점수에 따라 결과 비교

주의!! 각 논컨포미티 점수가 구성하는 예측집합의 형태를 기억해둘 것