

Conformal Prediction by Examples

7. MEPS + Jackknife+: Balancing the training-calibration tradeoff

Byol Kim

August 19, 2025

1. 훈련-보정 트레이드오프
2. 잭나이프 +
 잭나이프 + 설명
 잭나이프 + 주변 커버리지 보장
3. 잭나이프 +-애프터-붓스트랩

훈련-보정 트레이드오프

데이터 분할의 필요성

지금까지는 별도의 데이터로 사전 훈련된 모델의 예측 결과를 이용

Q 만약 사전 훈련된 모델이 없다면?

A

문제?

데이터 분할의 필요성

지금까지는 별도의 데이터로 사전 훈련된 모델의 예측 결과를 이용

Q 만약 사전 훈련된 모델이 없다면?

A 주어진 데이터로 모델 훈련과 예측집합 구성 모두 해야 함

문제?

데이터 분할의 필요성

지금까지는 별도의 데이터로 사전 훈련된 모델의 예측 결과를 이용

Q 만약 사전 훈련된 모델이 없다면?

A 주어진 데이터로 모델 훈련과 예측집합 구성 모두 해야 함

문제? 교환가능성 유지

훈련-보정 트레이드오프

주어진 데이터를 다음과 같이 분할

순수 훈련 데이터
(pure training data)

모델 및 논컨포미티 점수 훈련

보정 데이터
(calibration data)

임계값 및 예측집합 구성

Q 순수 훈련 데이터가 너무 적으면?

A

Q 보정 데이터가 너무 적으면?

A

훈련-보정 트레이드오프

주어진 데이터를 다음과 같이 분할

순수 훈련 데이터
(pure training data)

모델 및 논컨포미티 점수 훈련

보정 데이터
(calibration data)

임계값 및 예측집합 구성

Q 순수 훈련 데이터가 너무 적으면?

A 모델의 정확도 ↓

Q 보정 데이터가 너무 적으면?

A

훈련-보정 트레이드오프

주어진 데이터를 다음과 같이 분할

순수 훈련 데이터
(pure training data)

모델 및 논컨포미티 점수 훈련

보정 데이터
(calibration data)

임계값 및 예측집합 구성

Q 순수 훈련 데이터가 너무 적으면?

A 모델의 정확도 ↓

Q 보정 데이터가 너무 적으면?

A 커버리지의 변동 ↑

이번 시간에는

교차 적합을 교환가능한 데이터의 경우 데이터의 구조적 대칭성과 호환 가능하도록 개량한 방법론 잭나이프 + 를 적용하여 사전 훈련된 모델이 주어지지 않은 상황에서도 데이터의 정보를 효율적으로 사용하는 예측구간 구성

잭나이프 +

잭나이프 예측 (이론적 보장 χ)

- A : 학습 알고리즘 (learning algorithm)
- $\hat{f} = A[Z_1, \dots, Z_n]$: 전체 모델 (full model)
- $\hat{f}_{\setminus i} = A[Z_1, \dots, Z_{i-1}, Z_{i+1}, \dots, Z_n]$: 리브-원-아웃 모델 (leave-one-out model)
- $R_i = |Y_i - \hat{f}_{\setminus i}(X_i)|$: 리브-원-아웃 잔차 (leave-one-out residual)

$$\begin{aligned} C(x) &= \hat{f}(x) \pm \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \\ &= \left[\hat{f}(x) - \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha), \hat{f}(x) + \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \right] \end{aligned}$$

문제?

잭나이프 예측 (이론적 보장 χ)

- A: 학습 알고리즘 (learning algorithm)
- $\hat{f} = A[Z_1, \dots, Z_n]$: 전체 모델 (full model)
- $\hat{f}_{\setminus i} = A[Z_1, \dots, Z_{i-1}, Z_{i+1}, \dots, Z_n]$: 리브-원-아웃 모델 (leave-one-out model)
- $R_i = |Y_i - \hat{f}_{\setminus i}(X_i)|$: 리브-원-아웃 잔차 (leave-one-out residual)

$$\begin{aligned} C(x) &= \hat{f}(x) \pm \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \\ &= \left[\hat{f}(x) - \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha), \hat{f}(x) + \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \right] \end{aligned}$$

문제?

- $|Y_{n+1} - \hat{f}(X_{n+1})|$ 는 $R_1, \dots, R_n$ 과 교환 χ

잭나이프 예측 (이론적 보장 χ)

- A: 학습 알고리즘 (learning algorithm)
- $\hat{f} = A[Z_1, \dots, Z_n]$: 전체 모델 (full model)
- $\hat{f}_{\setminus i} = A[Z_1, \dots, Z_{i-1}, Z_{i+1}, \dots, Z_n]$: 리브-원-아웃 모델 (leave-one-out model)
- $R_i = |Y_i - \hat{f}_{\setminus i}(X_i)|$: 리브-원-아웃 잔차 (leave-one-out residual)

$$\begin{aligned} C(x) &= \hat{f}(x) \pm \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \\ &= \left[\hat{f}(x) - \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha), \hat{f}(x) + \text{Quantile}((R_i)_{i=1}^n; 1 - \alpha) \right] \end{aligned}$$

문제?

- $|Y_{n+1} - \hat{f}(X_{n+1})|$ 는 $R_1, \dots, R_n$ 과 교환 χ
- 이론적 보장 χ

잭나이프 + 예측 (이론적 보장 ✓)

잭나이프 예측의 동일한 표현

$$\begin{aligned} C(x) &= \left[\widehat{f}(x) - \text{Quantile} \left((R_i)_{i=1}^n; 1 - \alpha \right), \widehat{f}(x) + \text{Quantile} \left((R_i)_{i=1}^n; 1 - \alpha \right) \right] \\ &= \left[-\text{Quantile} \left(- \left(\widehat{f}(x) - R_i \right)_{i=1}^n; 1 - \alpha \right), \right. \\ &\quad \left. \text{Quantile} \left(\left(\widehat{f}(x) + R_i \right)_{i=1}^n; 1 - \alpha \right) \right] \end{aligned}$$

$\widehat{f}$ 를 $\widehat{f}_{\setminus i}$ 로 교체하면

$$|Y_{n+1} - \widehat{f}_{\setminus i}(X_{n+1})| \longleftrightarrow |Y_i - \widehat{f}_{\setminus i}(X_i)|$$

$$\begin{aligned} \widehat{C}(x) &= \left[-\text{Quantile} \left(- \left(\widehat{f}_{\setminus i}(x) - R_i \right)_{i=1}^n; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right), \right. \\ &\quad \left. \text{Quantile} \left(\left(\widehat{f}_{\setminus i}(x) + R_i \right)_{i=1}^n; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right] \end{aligned}$$

잭나이프 + 주변 커버리지 보장

$$(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1}) \sim P$$

가 교환가능하면

$$\mathbb{P} \left\{ Y_{n+1} \in \hat{C}(X_{n+1}) \right\} \geq 1 - 2\alpha$$

추가적으로, A 와 P 가 **알고리즘적으로 안정적** (*algorithmically stable*)이면

$$\mathbb{P} \left\{ Y_{n+1} \in \hat{C}(X_{n+1}) \right\} \approx 1 - \alpha$$

잭나이프 + 주변 커버리지 보장 설명

$$Y_{n+1} \notin \widehat{C}(X_{n+1})$$

$$\iff Y_{n+1} \leq -\text{Quantile} \left(- \left(\widehat{f}_{\setminus i}(X_{n+1}) - R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right)$$

$$\text{또는 } Y_{n+1} \geq \text{Quantile} \left(\left(\widehat{f}_{\setminus i}(x) + R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right)$$

전자의 경우 적어도 $(n+1)(1-\alpha)$ 보다 많은 i 에서 $Y_{n+1} \leq \widehat{f}_{\setminus i}(X_{n+1}) - R_i$:

$$\sum_{i=1}^n \mathbb{1} \left\{ Y_{n+1} - \widehat{f}_{\setminus i}(X_{n+1}) \leq -R_i \right\} \geq (n+1)(1-\alpha)$$

후자의 경우 적어도 $(n+1)(1-\alpha)$ 보다 많은 i 에서 $Y_{n+1} \geq \widehat{f}_{\setminus i}(X_{n+1}) + R_i$:

$$\sum_{i=1}^n \mathbb{1} \left\{ Y_{n+1} - \widehat{f}_{\setminus i}(X_{n+1}) \geq R_i \right\} \geq (n+1)(1-\alpha)$$

정리하면

$$Y_{n+1} \notin \widehat{C}(X_{n+1}) \implies \sum_{i=1}^n \mathbb{1} \left\{ |Y_{n+1} - \widehat{f}_{\setminus i}(X_{n+1})| \geq R_i \right\} \geq (n+1)(1-\alpha)$$

그런데 교환가능성 하에서

$$\mathbb{P} \left\{ \sum_{i=1}^n \mathbb{1} \left\{ |Y_{n+1} - \widehat{f}_{\setminus i}(X_{n+1})| \geq R_i \right\} \geq (n+1)(1-\alpha) \right\} \leq 2\alpha$$

잭나이프 + 주변 커버리지 보장 설명

n 개의 훈련 데이터에서 얻은 리브-원-아웃 모델 $\hat{f}_{\setminus i}$ 을 훈련 데이터와 테스트 데이터 포인트를 합한 데이터에서 얻은 리브-**투**-아웃 모델 $\hat{f}_{\setminus i, j}$ 로 보자

$$R_{ij} = |Y_j - \hat{f}_{\setminus i, j}(X_j)|$$

R_{ij} 값으로 다음 “토너먼트” 행렬을 정의:

$$A_{ij} = \mathbb{1}\{R_{ij} > R_{ji}\}$$

잭나이프 + 주변 커버리지 보장 설명

n 개의 훈련 데이터에서 얻은 리브-원-아웃 모델 $\hat{f}_{\setminus i}$ 을 훈련 데이터와 테스트 데이터 포인트를 합한 데이터에서 얻은 리브-**투**-아웃 모델 $\hat{f}_{\setminus i, j}$ 로 보자

$$R_{ij} = |Y_j - \hat{f}_{\setminus i, j}(X_j)|$$

R_{ij} 값으로 다음 “토너먼트” 행렬을 정의:

$$A_{ij} = \mathbb{1}\{R_{ij} > R_{ji}\}$$

해석 A 는 리그전에서 각 “경기” $\hat{f}_{\setminus i, j}$ 의 결과를 기록

잭나이프 + 주변 커버리지 보장 설명

n 개의 훈련 데이터에서 얻은 리브-원-아웃 모델 $\hat{f}_{\setminus i}$ 을 훈련 데이터와 테스트 데이터 포인트를 합한 데이터에서 얻은 리브-**투**-아웃 모델 $\hat{f}_{\setminus i,j}$ 로 보자

$$R_{ij} = |Y_j - \hat{f}_{\setminus i,j}(X_j)|$$

R_{ij} 값으로 다음 “토너먼트” 행렬을 정의:

$$A_{ij} = \mathbb{1}\{R_{ij} > R_{ji}\}$$

해석 A 는 리그전에서 각 “경기” $\hat{f}_{\setminus i,j}$ 의 결과를 기록

문제의 미포함 사건

$$\sum_{i=1}^n \mathbb{1}\left\{|Y_{n+1} - \hat{f}_{\setminus i}(X_{n+1})| \geq R_i\right\} \geq (n+1)(1-\alpha)$$

은 리그전에서 “선수” $(n+1)$ 이 본인이 참여하는 총 n 회의 “경기” 중 $(n+1)(1-\alpha)$ 이상의 “경기” 에서 “승리” 한 사건

잭나이프 + 주변 커버리지 보장 설명

리그전에서는 구조적으로 많은 경기에서 승리할 수 있는 선수 수가 제한됨

$(n + 1)(1 - \alpha)$ 이상의 횃수의 경기에서 승리할 수 있는 선수 수는 최대 $2(n + 1)\alpha$

$(n + 1)(1 - \alpha)$ 이상의
횃수의 경기에서 승리
하는 선수 수가 가장
많이 나오는 시나리오:
 $2(n + 1)\alpha$ 선수들이 나
머지 선수들과의 경기
에서 모두 승리

	모두 1	} $2\alpha(n + 1)$
모두 0	모두 0	
		} $(1 - 2\alpha)(n + 1)$

잭나이프 + 주변 커버리지 보장 설명

교환가능성은 소수의 승자 그룹에 속할 확률이 모든 선수들에게 동등함을 의미:

$$\begin{aligned} & \mathbb{P} \left[\begin{array}{c} (X_{n+1}, Y_{n+1}) \text{ 이} \\ (1 - \alpha)(n + 1) \text{ 이상 승리} \end{array} \right] \\ &= \frac{1}{n + 1} \sum_{i=1}^{n+1} \mathbb{P} \left[\begin{array}{c} (X_i, Y_i) \text{ 가} \\ (1 - \alpha)(n + 1) \text{ 이상 승리} \end{array} \right] \\ &= \frac{1}{n + 1} \mathbb{E} \left[\sum_{i=1}^{n+1} \mathbb{1} \left\{ \begin{array}{c} (X_i, Y_i) \text{ 가} \\ \geq (1 - \alpha)(n + 1) \text{ 이상 승리} \end{array} \right\} \right] \\ &= \frac{1}{n + 1} \mathbb{E} [\text{리그전에서 } (1 - \alpha)(n + 1) \text{ 이상 승리한 선수 수}] \\ &\leq 2\alpha \end{aligned}$$

왜 α 가 아니고 2α 인가?

- 컨포멀 예측은 모든 선수들이 동시에 겨루는 “경주”
 - 논컨포미티 점수의 쌍별 비교로 정의되는 이항 관계 (binary relation) 는 **전순서** (*total order*)를 정의

왜 α 가 아니고 2α 인가?

- 컨포멀 예측은 모든 선수들이 동시에 겨루는 “경주”
 - 논컨포미티 점수의 쌍별 비교로 정의되는 이항 관계 (binary relation) 는 **전순서 (total order)**를 정의
- 잭나이프 + 는 한 쌍씩 경기를 치르는 “리그전”
 - 논컨포미티 점수의 쌍별 비교 결과가 전순서로 이어지지 않음

왜 α 가 아니고 2α 인가?

- 컨포멀 예측은 모든 선수들이 동시에 겨루는 “경주”
 - 논컨포미티 점수의 쌍별 비교로 정의되는 이항 관계 (binary relation) 는 **전순서 (total order)**를 정의
- 잭나이프 + 는 한 쌍씩 경기를 치르는 “리그전”
 - 논컨포미티 점수의 쌍별 비교 결과가 전순서로 이어지지 않음
- 하지만 알고리즘 안정성은 각 리그 경기 결과의 전역 일관성을 시사
 - 따라서 이 조건이 만족되면 잭나이프 + 의 커버리지 역시 $1 - \alpha$

잭나이프 +-애프터-붓스트랩

$$\hat{C}(x) = \left[-Quantile \left(- \left(\hat{f}_{\setminus i}(x) - R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right), \right. \\ \left. Quantile \left(\left(\hat{f}_{\setminus i}(x) + R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right]$$

단점?

$$\hat{C}(x) = \left[-Quantile \left(- \left(\hat{f}_{\setminus i}(x) - R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right), \right. \\ \left. Quantile \left(\left(\hat{f}_{\setminus i}(x) + R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right]$$

단점? 교차 적합에 의한 계산 비용

- 잭나이프 + 의 경우, 총 n 번 모델 적합

$$\hat{C}(x) = \left[-Quantile \left(- \left(\hat{f}_{\setminus i}(x) - R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right), \right. \\ \left. Quantile \left(\left(\hat{f}_{\setminus i}(x) + R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right]$$

단점? 교차 적합에 의한 계산 비용

- 잭나이프 + 의 경우, 총 n 번 모델 적합

양상블 학습의 경우 단 한 번의 적합으로 모든 리브-원-아웃 모델 계산

- A: 기저 모델 학습 알고리즘
- φ : 집계 방법

for $b = 1, \dots, B$ do

$\{1, \dots, n\}$ 에서 $I_b = (i_{b,1}, \dots, i_{b,m})$ 를 재표본추출 또는 부표본추출

$$\hat{f}_b = A[Z_{i_{b,1}}, \dots, Z_{i_{b,m}}]$$

end for

return

$$\hat{f}_\varphi(x) = \varphi \left(\hat{f}_b(x) : b = 1, \dots, B \right)$$

아웃-오브-백 집계로 리브-원-아웃 모델 계산하기

- A : 기저 모델 학습 알고리즘
- φ : 집계 방법

for $b = 1, \dots, B$ do

$\{1, \dots, n\}$ 에서 $l_b = (i_{b,1}, \dots, i_{b,m})$ 를 재표본추출 또는 부표본추출

$$\hat{f}_b = A[Z_{i_{b,1}}, \dots, Z_{i_{b,m}}]$$

end for

for $i = 1, \dots, n$ do

return

$$\hat{f}_{\varphi \setminus i}(x) = \varphi \left(\hat{f}_b(x) : l_b \not\ni i \right)$$

end for

아웃-오브-백 집계로 리브-원-아웃 모델 계산하기

각 훈련 데이터에 대해 리브-원-아웃 모델을 처음부터 학습하기 보다, 아웃-오브-백 집계한 모델들로 대체하면 훨씬 효율적

Q 처음부터 학습하기?

A 총 Bn 번 기저 모델 적합

Q 아웃-오브-백 집계로 대체하기?

A 총 B 번 기저 모델 적합

문제?

아웃-오브-백 집계로 리브-원-아웃 모델 계산하기

각 훈련 데이터에 대해 리브-원-아웃 모델을 처음부터 학습하기 보다, 아웃-오브-백 집계한 모델들로 대체하면 훨씬 효율적

Q 처음부터 학습하기?

A 총 Bn 번 기저 모델 적합

Q 아웃-오브-백 집계로 대체하기?

A 총 B 번 기저 모델 적합

문제? 아웃-오브 백 모델 $\neq$ 리브-원-아웃 모델

리브-원-아웃 모델에 집계되는 기저 모델 수는 고정되어 있는데 아웃-오브-백 모델에 집계되는 기저 모델 수는 확률변수

아웃-오브-백 집계로 리브-원-아웃 모델 계산하기

각 훈련 데이터에 대해 리브-원-아웃 모델을 처음부터 학습하기 보다, 아웃-오브-백 집계한 모델들로 대체하면 훨씬 효율적

Q 처음부터 학습하기?

A 총 Bn 번 기저 모델 적합

Q 아웃-오브-백 집계로 대체하기?

A 총 B 번 기저 모델 적합

문제? 아웃-오브 백 모델 $\neq$ 리브-원-아웃 모델

리브-원-아웃 모델에 집계되는 기저 모델 수는 고정되어 있는데 아웃-오브-백 모델에 집계되는 기저 모델 수는 확률변수

애초에 총 기저 모델 수를 임의로 뽑으면 해결

잭나이프 +-애프터-붓스트랩 (jackknife+-after-bootstrap)

$B \sim \text{Binomial}(\tilde{B}, p)$, p 는 재표본추출의 경우 $\left(1 - \frac{1}{n+1}\right)^m$, 부표본추출의 경우 $1 - \frac{m}{n+1}$

for $b = 1, \dots, B$ do

$\{1, \dots, n\}$ 에서 $l_b = (i_{b,1}, \dots, i_{b,m})$ 를 재표본추출 또는 부표본추출

$$\hat{f}_b = A[Z_{i_{b,1}}, \dots, Z_{i_{b,m}}]$$

end for

for $i = 1, \dots, n$ do

$$\hat{f}_{\varphi \setminus i}(x) = \varphi \left(\hat{f}_b(x) : l_b \not\ni i \right), \quad R_i = |Y_i - \hat{f}_{\varphi \setminus i}(X_i)|$$

end for

$$\hat{C}(x) = \left[-\text{Quantile} \left(- \left(\hat{f}_{\varphi \setminus i}(x) - R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right), \right. \\ \left. \text{Quantile} \left(\left(\hat{f}_{\varphi \setminus i}(x) + R_i \right)_{i=1}^n ; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right]$$

요약

1. 훈련-보정 트레이드오프
2. 잭나이프 +
 잭나이프 + 설명
 잭나이프 + 주변 커버리지 보장
3. 잭나이프 +-애프터-붓스트랩

다음 실습 내용

코드를 완성하여 직접 잭나이프 + 예측 구현