

Conformal Prediction by Examples

5. MEPS + Weighted conformal: When the data are no longer exchangeable

Byol Kim

August 19, 2025

1 부에서는

직접 구현을 통해 컨포멀 예측과 관련된 기본적인 아이디어 체득

1. ImageNet 과 간단한 논컨포미티 점수를 사용한 이미지 분류 예제
2. 분류 난이도를 고려한 논컨포미티 점수를 사용하여 재시도
3. MEPS 에 세 가지 다른 구조의 논컨포미티 점수를 사용한 회귀 예제
4. 분할 컨포멀 예측의 커버리지 진단

2 부에서는

다양한 문제로 컨포멀 예측 기법을 확장한다 했을 때 시작 점으로 잡을 수 있는 주제들을 선택

5. 교환가능하지 않은 데이터

~~> **가중 컨포멀 예측 (weighted conformal prediction)**

6. 위험 제어 관점에서 본 컨포멀 예측

~~> **컨포멀 위험 제어 (conformal risk control)**

7. 모델 훈련-보정 트레이드오프 개선

~~> **잭나이프 +(jackknife+)**

이번 시간에는

가중 컨포멀 예측으로 교환가능성을 위반하는 데이터에도 컨포멀 예측 기법을 적용해보기

1. 공변량 변화

2. 공변량 변화 하에서 컨포멀 예측

교환가능성 하에서 주변 커버리지 보장의 증명

그럼, 교환가능성 없이는?

공변량 변화 하에서

3. 가중 컨포멀 예측 워크플로

가중 분위수 계산

오라클 가중치를 모를 때


4. 다음 실습 내용

공변량 변화

교환가능성 위반이 의심되는 상황들

1. 시공간적 의존성 (spatio-temporal dependence)
2. 분포 변화 (distribution shift), 공변량 변화 (covariate shift)
 - **예** 한 병원의 데이터로 훈련한 모델을 환자 구성이 다른 타 병원에 배포

$$(X_i, Y_i) \stackrel{\text{i.i.d.}}{\sim} P_X \times P_{Y|X}, \quad i = 1, \dots, n$$
$$(X_{n+1}, Y_{n+1}) \sim Q_X \times P_{Y|X}$$



Angelopoulos, A. N., Barber, R. F., & Bates, S. (2024). Theoretical foundations of conformal prediction.

공변량 변화 하에서 컨포멀 예측

교환가능성 (exchangeability) 이란?

확률변수 $Z_1, \dots, Z_n$ 가

$$\forall \sigma \in \mathfrak{S}_n, \quad (Z_{\sigma(1)}, \dots, Z_{\sigma(n)}) \stackrel{d}{=} (Z_1, \dots, Z_n)$$

을 만족하면 **교환가능 (exchangeable)**하다고 한다.

- **예** $Z_1, \dots, Z_n$ 이 결합 pdf 또는 pmf $f(z_1, \dots, z_n)$ 을 갖는 경우,

$$\forall \sigma \in \mathfrak{S}_n, \quad f(z_{\sigma(1)}, \dots, z_{\sigma(n)}) = f(z_1, \dots, z_n)$$

교환가능성 하에서 바닐라 컨포멀 예측의 주변 커버리지 보장

1. **Validity** ✓ 설정 상 오류 확률 = 실제 오류 확률

주변 커버리지 보장

$(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ 이 교환가능하면

$$\mathbb{P} \left\{ Y_{n+1} \in \hat{C}(X_{n+1}) \right\} \geq 1 - \alpha$$

직관

- $(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ 이 교환가능
- $S_i = s(X_i, y_i)$ 값까지만 관측되었을 때
 - $S_{n+1} = S_i$ 일 확률은 $1/(n+1)$ 로 동일
 - $S_{n+1} \leq S_{(k)}$ 일 확률은 $k/(n+1)$ 이거나 그 이상

리스트 $z = (z_1, \dots, z_n)$ 의 α -분위수

$$\text{Quantile}(z; \alpha) = \text{Quantile} \left(\frac{1}{n} \sum_{i=1}^n \delta_{z_i}; \alpha \right) = \inf \left\{ v \in \mathbb{R} : \hat{F}_z(v) \geq \alpha \right\}$$
$$\hat{F}_z(v) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{z_i \leq v\}$$

Lemma

$$z_{n+1} \leq \text{Quantile} \left(\frac{1}{n} \sum_{i=1}^n \delta_{z_i}; \left(1 + \frac{1}{n}\right) \alpha \right)$$
$$\iff z_{n+1} \leq \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^{n+1} \delta_{z_i}; \alpha \right)$$

교환가능성 하에서 주변 커버리지 보장의 증명

바닐라 컨포멀 예측 주변 커버리지 보장

$$\begin{aligned} & \mathbb{P} \left\{ Y_{n+1} \in \widehat{C}(X_{n+1}) \right\} \\ &= \mathbb{P} \left\{ S_{n+1} \leq \text{Quantile} \left(\frac{1}{n} \sum_{i=1}^n \delta_{S_i}; \left(1 + \frac{1}{n} \right) (1 - \alpha) \right) \right\} \\ &= \mathbb{P} \left\{ S_{n+1} \leq \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^{n+1} \delta_{S_i}; 1 - \alpha \right) \right\} \\ &\geq 1 - \alpha \end{aligned}$$

교환가능성 하에서 주변 커버리지 보장의 증명

$Z_i = (x_i, y_i)$, $Z = (z_1, \dots, z_n, z_{n+1})$ 에 대해, 사건 E_Z 를 다음과 같이 정의:

$$\{Z_1, \dots, Z_n, Z_{n+1}\} = \{z_1, \dots, z_n, z_{n+1}\}$$

교환가능성 하에서 $S_{n+1}|E_Z$ 의 분포를 구하기 위해 $\mathbb{P}\{S_{n+1} = s_i | E_Z\}$ 를 계산:

$$\begin{aligned}\mathbb{P}\{S_{n+1} = s_i | E_Z\} &= \mathbb{P}\{Z_{n+1} = z_i | E_Z\} \\&= \frac{\sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})}{\sum_{\sigma} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})} \\&= \frac{\sum_{\sigma: \sigma(n+1)=i} f(z_1, \dots, z_{n+1})}{\sum_{\sigma} f(z_1, \dots, z_{n+1})} \\&= \frac{n!}{(n+1)!} \\&= \frac{1}{n+1}\end{aligned}$$

단순화를 위해, 결합 pdf f 를 갖는다 가정

교환가능성 하에서 주변 커버리지 보장의 증명

사건 E_z 에서 $S_{n+1} = s_i$ 일 확률은 $1/(n+1)$ 로 균등. 따라서

$$\mathbb{P} \left\{ S_{n+1} \leq \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^{n+1} \delta_{S_i}; 1 - \alpha \right) \mid E_z \right\} \geq 1 - \alpha$$

양변에 $\mathbb{E}$ 를 취하면

$$\mathbb{P} \left\{ S_{n+1} \leq \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^{n+1} \delta_{S_i}; 1 - \alpha \right) \right\} \geq 1 - \alpha$$

그럼, 교환가능성 없이는?

핵심!! $S_{n+1}|E_Z$ 의 분포 계산

$$\begin{aligned}\mathbb{P}\{S_{n+1} = s_i \mid E_Z\} &= \mathbb{P}\{Z_{n+1} = z_i \mid E_Z\} \\ &= \frac{\sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})}{\sum_{\sigma} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})} \\ &= \frac{\sum_{\sigma: \sigma(n+1)=i} f(z_1, \dots, z_{n+1})}{\sum_{\sigma} f(z_1, \dots, z_{n+1})}\end{aligned}$$

일반적으로 $S_{n+1}|E_Z$ 의 분포는 가중치 $\frac{\sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})}{\sum_{\sigma} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})}$ 를 갖는 경험적 분포로 표현되기는 하나 계산이 어려움

하지만 공변량 변화 하에서는 상당히 단순화가 가능!!

공변량 변화 하에서

$$\begin{aligned} f(z_1, \dots, z_n, z_{n+1}) &= \left\{ \prod_{i=1}^n f_X(x_i) f_{Y|X}(y_i | x_i) \right\} \tilde{f}_X(x_{n+1}) f_{Y|X}(y_{n+1} | x_{n+1}) \\ &= \left\{ \prod_{i=1}^n f_X(x_i) f_{Y|X}(y_i | x_i) \right\} f_X(x_{n+1}) f_{Y|X}(y_{n+1} | x_{n+1}) \frac{\tilde{f}_X(x_{n+1})}{f_X(x_{n+1})} \\ &= \underbrace{\prod_{i=1}^{n+1} f_X(x_i) f_{Y|X}(y_i | x_i)}_{g(z_1, \dots, z_n, z_{n+1})} \underbrace{\frac{\tilde{f}_X(x_{n+1})}{f_X(x_{n+1})}}_{h(x_{n+1})} \end{aligned}$$

$f_X, f_{Y|X}, \tilde{f}_X$ 는 각각 $P_X, P_{Y|X}, Q_X$ 의 pdf

공변량 변화 하에서

$$\begin{aligned}\sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)}) &= \sum_{\sigma: \sigma(n+1)=i} g(z_{\sigma(1)}, \dots, z_{\sigma(n+1)}) h(x_{\sigma(n+1)}) \\ &= \sum_{\sigma: \sigma(n+1)=i} g(z_1, \dots, z_n, z_{n+1}) h(x_i) \\ &= n! g(z_1, \dots, z_n, z_{n+1}) h(x_i)\end{aligned}$$

$$\begin{aligned}\sum_{\sigma} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)}) &= \sum_i \sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)}) \\ &= \sum_i n! g(z_1, \dots, z_n, z_{n+1}) h(x_i) \\ &= n! g(z_1, \dots, z_n, z_{n+1}) \left(\sum_i h(x_i) \right)\end{aligned}$$

공변량 변화 하에서

$$\frac{\sum_{\sigma: \sigma(n+1)=i} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})}{\sum_{\sigma} f(z_{\sigma(1)}, \dots, z_{\sigma(n+1)})} = \frac{h(x_i)}{\sum_i h(x_i)}$$

정리하면

$$\mathbb{P}\{S_{n+1} = s_i | E_Z\} = \frac{h(x_i)}{\sum_i h(x_i)}, \quad h(x_i) = \frac{\tilde{f}_X}{f_X}(x_i) = \frac{dQ_X}{dP_X}(x_i)$$

즉

$$S_{n+1} | E_Z \sim \sum_{i=1}^{n+1} w(x_i) \delta_{s_i}, \quad w(x_i) \propto \frac{dQ_X}{dP_X}(x_i)$$

해석 각 데이터 값에 대한 가중치는 변화 후 공변량 분포에서 x_i 를 관측할 우도비와 비례

절차적 변화에 대한 의미

$(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ 이 교환가능하면

$$\hat{C}(x) = \left\{ y : s(x, y) \leq \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^n \delta_{S_i} + \frac{1}{n+1} \delta_{\infty}; 1 - \alpha \right) \right\}$$

$(X_1, Y_1), \dots, (X_n, Y_n)$ 와 (X_{n+1}, Y_{n+1}) 사이에 공변량 변화가 있으면

$$\hat{C}(x) = \left\{ y : s(x, y) \leq \text{Quantile} \left(\sum_{i=1}^n w(X_i) \delta_{S_i} + w_{n+1}(x) \delta_{\infty}; 1 - \alpha \right) \right\}$$
$$w(X_i) \propto h(X_i) = \frac{\tilde{f}_X}{f_X}(X_i) = \frac{dQ_X}{dP_X}(X_i)$$

주의!! X_{n+1} 의 값에 따라 가중치들과 임계값이 변화. 가중치의 합이 1 이 되도록 정규화할 때 $h(X_{n+1})$ 의 영향을 받음

가중 컨포멀 예측에 대한 비교

1. 이론적으로는 어떤 데이터 생성 과정으로도 컨포멀 예측을 확장할 수 있는 방법을 제시하는 강력한 프레임워크

가중 컨포멀 예측에 대한 비교

1. 이론적으로는 어떤 데이터 생성 과정으로도 컨포멀 예측을 확장할 수 있는 방법을 제시하는 강력한 프레임워크
2. 주어진 예측 문제에 대해 계산적으로 실현 가능한 절차로 이어질지 여부는 해당 문제의 특정 구조에 크게 의존

가중 컨포멀 예측 워크플로

바닐라 분할 컨포멀 예측 워크플로

주어진 것 사전 훈련된 예측 모델 $\hat{f}$

1. Score

$$s(x, y) = s(x, y; \hat{f})$$

2. Calibrate

$$\begin{aligned} S_i &= s(X_i, Y_i), \quad i = 1, \dots, n \\ \hat{q} &= \text{Quantile} \left(\frac{1}{n} \sum_{i=1}^n \delta_{S_i}; \left(1 + \frac{1}{n}\right) (1 - \alpha) \right) \\ &= \text{Quantile} \left(\frac{1}{n+1} \sum_{i=1}^n \delta_{S_i} + \frac{1}{n+1} \delta_{\infty}; 1 - \alpha \right) \end{aligned}$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}\}$$

가중 분할 컨포멀 예측 워크플로

주어진 것 사전 훈련된 예측 모델 $\hat{f}$, $X_{n+1} = x$ 에 대한 가중치 $w = (w_1, \dots, w_n, w_{n+1})$, $w_i \geq 0$, $\sum_i w_i = 1$

1. Score

$$s(x, y) = s(x, y; \hat{f})$$

2. Calibrate

$$S_i = s(X_i, Y_i), \quad i = 1, \dots, n$$



$$\hat{q}_w = \text{Quantile} \left(\sum_{i=1}^n w_i \delta_{S_i} + w_{n+1} \delta_{\infty}; 1 - \alpha \right)$$

3. Construct

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}_w\}$$

가중 분위수 계산

1. $s_1, \dots, s_n$ 을 순서대로 정렬하는 순열 π 계산
2. π 로 정렬된 가중치의 누적 합이 최초로 $1 - \alpha$ 를 넘는 위치 계산
3. $\hat{q}_w$ 는 2 의 위치에 해당하는 논컨포미티 점수



Angelopoulos, A. N., Barber, R. F., & Bates, S. (2024). Theoretical foundations of conformal prediction.

오라클 가중치를 모를 때

공변량 변화 전 데이터를 0, 공변량 변화 후 데이터를 1

$$C_i = \begin{cases} 0 & i = 1, \dots, n \\ 1 & i = n + 1, \dots, n + m \end{cases}$$

데이터의 공변량 부분만 사용하여 적합한 이진 분류기의 추정 확률을 이용

$$\frac{\mathbb{P}\{C = 1 \mid X = x\}}{\mathbb{P}\{C = 0 \mid X = x\}} = \frac{\mathbb{P}\{C = 1\}}{\mathbb{P}\{C = 0\}} \frac{dQ_X}{dP_X}(x)$$

이므로

$$\hat{p}(x) = \mathbb{P}\{C = 1 \mid X = x\}$$

일 때

$$\hat{h}(x) = \frac{\hat{p}(x)}{1 - \hat{p}(x)}$$

어차피 정규화할 것이므로 우도비는 비례상수까지만 정확하면 됨

다음 실습 내용

MEPS(Medical Expenditure Panel Survey, 의료비 지출 패널 조사) 데이터

- X: 환자의 인구학적 특성 및 건강 상태
- Y: 로그 의료지출 (단위: 로그 \$)

튜토리얼 데이터셋에는 다음 분위수 회귀 결과도 포함:

- pred: 로그 의료지출의 모델 예측값

$$h(x) = \exp(x^\top \beta)$$

여기서, β 의 값은 암 중증도 공변량에 대해서는 1, 다른 공변량에 대해서는 0
보정 데이터에 비해 테스트 데이터에 암 중증도가 높은 환자들의 비율이 높
음

가중 분할 컨포멀 예측 워크플로: 다음 실습의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$, 오라클 또는 추정 우도비 함수 h

1. **Score** $s(x, y) = |y - \hat{f}(x)|$
2. **Calibrate** $S_i = s(X_i, Y_i), i = 1, \dots, n$

각 테스트 $X_{n+1} = x_{n+1}$ 에 대해

- (가중치 계산) $h(x_{n+1}), w_i = h(X_i) / \sum_{j=1}^{n+1} h(x_j), i = 1, \dots, n + 1$
- (가중 임계값 계산)

$$\hat{q}_w = \text{Quantile} \left(\sum_{i=1}^n w_i \delta_{S_i} + w_{n+1} \delta_{\infty}; 1 - \alpha \right)$$

- **Construct**

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}_w\} =$$

가중 분할 컨포멀 예측 워크플로: 다음 실습의 경우

주어진 것 사전 훈련된 예측 모델 $\hat{f}$, 오라클 또는 추정 우도비 함수 h

1. **Score** $s(x, y) = |y - \hat{f}(x)|$
2. **Calibrate** $S_i = s(X_i, Y_i), i = 1, \dots, n$

각 테스트 $X_{n+1} = x_{n+1}$ 에 대해

- (가중치 계산) $h(x_{n+1}), w_i = h(X_i) / \sum_{j=1}^{n+1} h(x_j), i = 1, \dots, n + 1$
- (가중 임계값 계산)

$$\hat{q}_w = \text{Quantile} \left(\sum_{i=1}^n w_i \delta_{S_i} + w_{n+1} \delta_{\infty}; 1 - \alpha \right)$$

- **Construct**

$$\hat{C}(x) = \{y : s(x, y) \leq \hat{q}_w\} = [\hat{f}(x) - \hat{q}_w, \hat{f}(x) + \hat{q}_w]$$

요약

1. 공변량 변화

2. 공변량 변화 하에서 컨포멀 예측

교환가능성 하에서 주변 커버리지 보장의 증명

그럼, 교환가능성 없이는?

공변량 변화 하에서

3. 가중 컨포멀 예측 워크플로

가중 분위수 계산

오라클 가중치를 모를 때

4. 다음 실습 내용

다음 실습 내용

코드를 완성하여 직접 가중 컨포멀 예측 구현

오라클 가중치를 사용하여 구현해본 후, 추정 가중치를 사용하여 구현

주의!! 가중치 임계값 계산. 임계값을 한 번 계산하는 것이 아니라, x_{n+1} 의 값에 따라 재계산

생각해볼 거리 실용적으로 좋은 성능을 발휘하기 위해 충족되어야 할 조건들